

基于反事实情感因果推理的零样本视频情感描述生成

Zero-shot Video Emotional Description Generation Based on Counterfactual Emotional Causal Reasoning

期刊：	中国科学: 信息科学
稿件ID：	SSI-2025-0435.R2
稿件栏目：	论文
作者提交日期：	2026-03-08
参与作者列表：	柯吕, 黄玧璇, 刘袁缘, 钱莹, 唐厂, 邹志强, 张洪艳
关键词：	视频情感描述, 零样本学习, 反事实因果推理, 情感幻觉, 生成式视觉-语言模型
英文关键词：	Video Emotional Description, Zero-shot Learning, Counterfactual Causal Reasoning, Emotional Hallucination, Generative Vision-Language Model
学科领域：	计算机视觉/图像处理
专题：	

Accepted
For Review Only

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

中国科学:信息科学 在审文章 onlinelatex

SCIENTIA SINICA Informationis

论文

基于反事实情感因果推理的零样本视频情感描述生成

柯吕[1†], 黄玮璇[1†], 刘袁缘[1*], 钱莹[1], 唐厂[2], 邹志强[3], 张洪艳[1]

1. 中国地质大学 (武汉) 计算机学院, 武汉 430078
2. 华中科技大学软件学院, 武汉 430074
3. 南京邮电大学计算机学院, 南京 210023

* 通信作者. E-mail: liuyy@cug.edu.cn

† 同等贡献

国家自然科学基金面上项目 (批准号: 62076227) 资助项目

摘要 视频情感描述旨在为视频序列生成富含情感语义的自然语言文本, 在人机交互和数字人等领域具有广泛应用前景. 然而, 现有方法大多依赖大规模人工标注的视频-情感描述对进行训练, 导致成本高昂. 尽管近年来视觉-语言基础模型 (如 BLIP) 具备一定的零样本推理能力, 但在细粒度情感理解和描述真实性方面仍存在不足. 为此, 本文提出一种反事实情感因果推理增强 BLIP 方法, 以实现无需人工标注的零样本视频情感描述. 该方法包括两个模块: 情感伪标签生成与学习和反事实情感因果推理学习. 前者为每个视频构建涵盖全局内容, 全局情感, 人脸表情三个维度的多粒度情感伪标签, 并结合情感语义描述损失使 BLIP 具备细粒度情感建模能力. 后者基于自然直接效应建模视觉与语言间的因果关系, 以缓解情感幻觉问题. 在推理阶段, 将视频输入增强后的 BLIP 能够生成准确且连贯的情感描述. 本文在视频情感描述数据集 MAFW 和 DFEW 上进行了域内和域外实验. 实验结果表明, 本文方法在四个描述生成指标上均优于现有方法, 验证了该方法的有效性与优越性.

关键词 视频情感描述, 零样本学习, 反事实因果推理, 情感幻觉, 生成式视觉-语言模型

1 引言

视频情感描述是视频描述任务中一个具有挑战性的子方向, 旨在对视频序列进行情感理解和分析, 生成富含情感语义的自然语言文本 [1]. 视频情感描述具有重要的应用价值, 可广泛应用于人机交互, 数字人, 多媒体舆情分析以及智能推荐系统等领域 [2~5].

目前已开展了一些关于视频情感描述的研究 [1,6]. 例如 Song 等人 [6] 提出 CANet, 采用视觉和文本编码器提取多模态特征, 并结合 LSTM [7] 与跨模态注意力机制, 实现情感描述的生成. Wang 等人 [1] 提出 ECPA, 该方法利用视觉和文本情感提示分别提取视频和文本中的情感特征, 随后通过跨模态对齐实现情感语义匹配, 最

引用格式: 柯吕, 黄玮璇, 刘袁缘, 等. 基于反事实情感因果推理的零样本视频情感描述生成. 中国科学: 信息科学, 在审文章
Ke Lv, Huang Yuxuan, Liu Yuanyuan, et al. Zero-shot video emotional description generation based on counterfactual emotional causal reasoning. Sci Sin Inform, for review

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

后通过多模态 Transformer [8] 生成精细的情感描述. 尽管这些方法取得了一定进展, 但其性能严重依赖高质量的视频-情感语言标注, 这带来了两个关键问题: 首先, 由于情感表达存在复杂性和主观性, 人工标注难以准确捕捉情感信息, 导致标注成本高昂且一致性较差; 其次, 现有视频情感描述数据集 (如 EmVidCap [9] 和 MAFW [10]) 的数据规模有限且标注粒度不一致, 难以满足生成模型对大规模高质量数据的需求, 从而限制了其实际应用能力. 因此, 探索**无需人工标注**的**零样本视频情感描述方法**不仅有助于降低成本, 也对提升模型的泛化能力具有重要意义.

随着大模型的提出, 一些研究开始关注无需人工标注数据的零样本视频描述. 例如, Su 等人 [11] 结合视觉语言模型 CLIP [12] 和大语言模型 GPT-2 [13], 利用相似性得分来引导文本生成, 确保生成的描述与视觉语义相关. 然而, 这类方法中的语言模型无法直接利用视觉信息, 导致生成的描述往往缺乏细节. 因此, Li 等人 [14] 提出生成式视觉-语言基础模型 BLIP (Bootstrapping Language-Image Pre-training), 该模型具备一定的零样本推理能力. 然而, BLIP 更注重视频整体内容的建模, 往往忽视细粒度的情感特征, 导致难以生成精细情感描述. 随后, 视觉-语言大模型 InternVL2 [15] 被提出, 该模型具备一定的情感表达能力, 但其生成的情感描述仍存在情感刻画不够精细以及情感幻觉问题.

尽管上述方法在零样本视频描述任务中取得了一定进展, 但在应对更复杂的视频情感描述任务时, 仍存在以下两个显著问题:

(1) **精细情感语义理解能力有限**. 由于缺乏大规模情感标注数据的训练, 现有方法难以充分捕捉人脸表情等非语言线索中的细微情感变化, 这导致生成的描述在情感丰富性与准确性方面存在不足. 如图1所示, BLIP 仅能生成人物的动作描述, 而无法生成情感描述.

(2) **情感幻觉问题普遍存在**. 现有方法缺乏视觉和情感之间的关联建模, 常出现生成的情感描述与情感视觉内容不符或是情感类别预测错误的情况. 如图1所示, 视频中人物的情感是 “surprise”, 对应人脸 AU (Action Unit) 描述应为 “wide eyes”, 但大模型 InternVL2 却生成了几乎完全相反的描述 “eyes are slightly narrowed”, 并将情感错误预测为 “contemplative”.

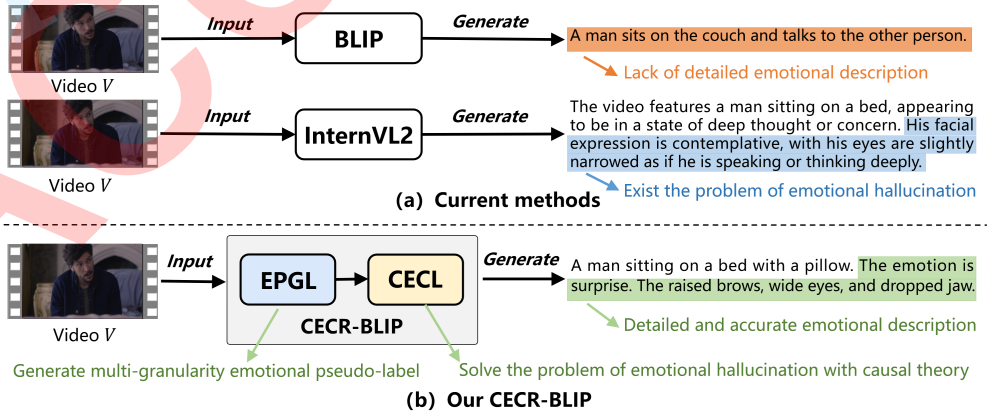


图 1 (网络版彩图) 本文动机及方法的直观结果. 现有方法仅能生成粗粒度情感描述且存在情感幻觉. 我们的反事实情感因果推理增强 BLIP (Counterfactual Emotional Causal Reasoning enhanced BLIP, CECR-BLIP) 结合情感伪标签生成与学习 (Emotional Pseudo-label Generation and Learning, EPGL) 和反事实情感因果推理学习 (Counterfactual Emotional Causal reasoning Learning, CECL) 能够生成更加精细准确的情感描述

Figure 1 (Color online)The motivation of this paper and the intuitive results of its methodology. Existing methods can only generate coarse-grained emotional description and suffer from emotional hallucination. In contrast, our Counterfactual Emotional Causal Reasoning enhanced BLIP (CECR-BLIP), by integrating Emotional Pseudo-label Generation and Learning (EPGL) and Counterfactual Emotional Causal reasoning Learning(CECL), can generate more fine-grained and accurate emotional description

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

针对上述挑战，本文提出一种新颖的**反事实情感因果推理增强 BLIP (Counterfactual Emotional Causal Reasoning enhanced BLIP, CECR-BLIP)** 方法，以推动 BLIP 实现零样本视频情感描述. 图1展示了本文的动机和方法的直观结果. 该方法通过训练显著增强了 BLIP 的情感语义理解能力，有效缓解了在生成过程中易出现的情感幻觉问题，最终实现**零样本**视频情感描述.

本文的主要贡献如下:

(1) 我们提出了反事实情感因果推理增强 BLIP (CECR-BLIP) 方法，该方法包括两个模块: 情感伪标签生成与学习模块和反事实情感因果推理学习模块，实现了零样本视频情感描述. 据我们所知，这是该任务中首个无需人工标注的视频-情感描述对的有效零样本学习方法.

(2) 我们设计了情感伪标签生成与学习模块，利用 BLIP 和 GPT-4 为每个视频生成了多粒度情感伪标签，并通过引入情感语义描述损失使模型获得对细粒度情感信息的理解能力.

(3) 我们设计了反事实情感因果推理学习模块，通过引入自然直接效应建模视觉与文本间的情感因果关系并利用情感标签加以监督，从而有效缓解情感幻觉问题.

(4) 我们在两个视频情感描述数据集 (MAFW 和 DFEW) 上进行了域内和域外两类零样本实验. 实验结果表明，我们的 CECR-BLIP 在每种设置下均优于现有方法. 与基线方法 BLIP 相比，CECR-BLIP 在四个评价指标 (即 BLEU-4, METEOR, ROUGE-L 和 CIDER) 上分别实现了 159.49%, 107.47%, 37.03% 和 71.01% 的平均相对提升，验证了其在零样本视频情感描述任务中的优越性.

2 相关工作

2.1 视频情感描述生成

在视频情感描述研究的发展历程中，Wang 等人 [9] 率先提出了这一任务，并发布了 EmVidCap 数据集，该数据集创新性地引入情感副词来表征情感信息. 此外，他们设计了事实转移框架 (FT)，该框架由独立的事实模块和情感模块组成，在解码的每一步通过对输出概率加权平均，实现了情感信息与事实信息的有效融合. 随后，Song 等人 [6] 提出了一种新的上下文注意网络，该方法通过语义丰富的上下文学习来识别并生成情感描述. 在每个时间步，该网络首先从输入视频和先前生成的词语中提取视觉与文本特征，随后利用注意力机制对这些特征进行建模，以捕获上下文信息并生成描述. 之后，Song 等人 [16] 又提出了一种情感先验意识网络. 该网络首先对视频中的情感进行识别，并利用识别结果来指导视频描述的生成. 在方法设计上，它结合了心理分类与日常自然词汇的优势以更好地理解情感，并采用树状结构进行情感建模. 然而，Wang 等人 [1] 研究发现现有方法在细粒度情感描述方面存在局限，特别是难以准确描述人脸表情动作. 为此，他们提出了基于跨模态提示和对齐的新方法，通过设计两级 (情感识别级和面部动作单元级) 可学习视觉提示，并引入两级情感导向的对齐学习机制，显著提升了模型在全局和局部情感语义捕获与整合方面的能力. 尽管研究方法不断进步，但视频情感描述仍面临数据集资源匮乏的挑战，因此研究零样本视频情感描述方法至关重要.

2.2 零样本视频描述生成

不同于传统分类任务中以“未见过类别样本”为核心的零样本设定，在视觉–语言生成任务中，零样本视频描述生成指模型在训练阶段未使用任何人工标注的视频–文本配对数据进行训练 [17~19]，而在推理阶段仍需对输入视频生成自然语言描述. 通常，这类方法可以通过免训练、仅利用视觉或文本标注信息来提供训练引导. 基于此设定，现有一些研究已能够在无需人工标注数据的条件下，完成零样本视频描述任务. 例如 Tewel 等人 [20] 提出 ZSV2T 方法，将视觉语言模型 CLIP [12] 与大语言模型 GPT-2 [13] 相结合，以实现对视频内容的整体描述. 然而，由于这类方法的语言模型缺乏对视觉内容的建模，导致生成的描述容易偏离真实内容. 因此，Li 等

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

人 [14] 提出了视觉-语言基础模型 BLIP, 该模型通过联合图像–文本预训练, 实现了跨模态语义对齐, 并在描述生成任务上展现出良好的零样本迁移能力. 同时, 也有部分研究仅基于文本标注训练, 未能充分发挥视频—文本对齐信息的作用. Nukrai 等人 [21] 通过训练一个解码器, 将 CLIP 文本编码器生成的嵌入向量转换回原始文本, 且该解码器仅依赖文本数据即可训练. Yang 等人 [18] 提出了 MultiCapCLIP, 该方法引入概念提示并对其进行自动编码, 以学习语言风格, 从而生成符合期望的描述. 这类方法虽然在数据集文本语料库上进行了专门训练, 并在部分指标上取得了较好效果, 但其在情感描述任务中的表现仍存在明显不足.

2.3 反事实因果推理

反事实因果推理是一种通过假设 “如果……将会……” 的形式来推断在不同条件下可能产生的结果的方法 [22], 其核心在于分析未实际发生的情境 (反事实) 对结果的影响. 例如, 某人计划前往餐厅就餐, 但由于出发较晚而遇到餐厅已打烊的情况 (实际事件), 此时可能会思考: “如果我能更早出门 (假设条件), 餐厅就不会打烊 (预期结果)”. 这一思考过程正是反事实推理的体现. 大多数关于反事实因果推理的方法 [23~25] 是针对分类任务进行的研究, 并且也常用于多模态情感识别任务上. 例如, Yang 等人 [26] 提出了一种基于因果关系的多模态反事实推理框架, 通过对比真实输入与反事实输入, 有效缓解了数据集中的标签与上下文偏差. 之后, Yang 等人 [27] 又提出一种基于因果干预的上下文感知情感识别方法, 利用后门调整消除情境偏差, 以增强模型对真实情感表征的学习能力. 近年来, 反事实因果推理也被引入到生成任务中. Cao 等人 [28] 将其应用于图像描述任务, 提出一种基于因果推理的通用图像描述框架, 并通过引入总效应和自然直接效应来缓解幻觉, 从而提升图像描述的准确性与可解释性.

3 本文方法

3.1 总体方法

本文提出一种反事实情感因果推理增强 BLIP (Counterfactual Emotional Causal Reasoning enhanced BLIP, CECR-BLIP) 的零样本视频情感描述生成方法, 旨在通过训练增强 BLIP 对细粒度情感信息的理解能力并缓解生成描述中的情感幻觉问题. 方法整体架构如图2所示, 由情感伪标签生成与学习 (Emotional Pseudo-label Generation and Learning, EPGL) 和反事实情感因果推理学习 (Counterfactual Emotional Causal reasoning Learning, CECL) 组成. 其中, EPGL 为每个视频生成多粒度情感伪标签, 并通过情感语义描述损失训练 BLIP 模型, 使其具备细粒度情感理解能力; 在此基础上, CECL 继承 EPGL 训练得到的 BLIP 参数, 通过在共享参数条件下对事实与反事实输入进行情感描述生成, 比较仅由输入变化引起的输出差异以估计自然直接效应, 从而引导模型学习视觉输入对情感描述生成的直接因果影响, 并结合情感标签监督以减少情感幻觉.

3.2 BLIP 简述

BLIP [14] 是一种用于联合建模图像与文本信息的视觉-语言预训练模型, 由视觉编码器与文本解码器双模态结构组成. 其视觉编码器采用了 Vit [29] 结构, 记作 φ_V, 用于对视频 V 进行编码, 提取视觉特征. 其提取视觉特征 F_V 的公式如下:

$$F_V = \varphi_V(V). \tag{1}$$

文本解码器基于 Transformer [8] 架构, 记为 φ_T, 用于将提取到的视觉特征与已经生成的文本共同作为输入, 逐步生成文本描述, 公式如下:

$$S_t = \varphi_T(F_V, S_{<t}), \tag{2}$$

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

其中, S_t 为第 t 步生成的文本, F_V 是视觉编码器提取到的特征, $S_{<t}$ 为已经生成的文本. 该解码器通过交叉注意力机制融合视觉信息和已生成的文本信息, 实现逐词生成, 最终生成完整的视频描述.

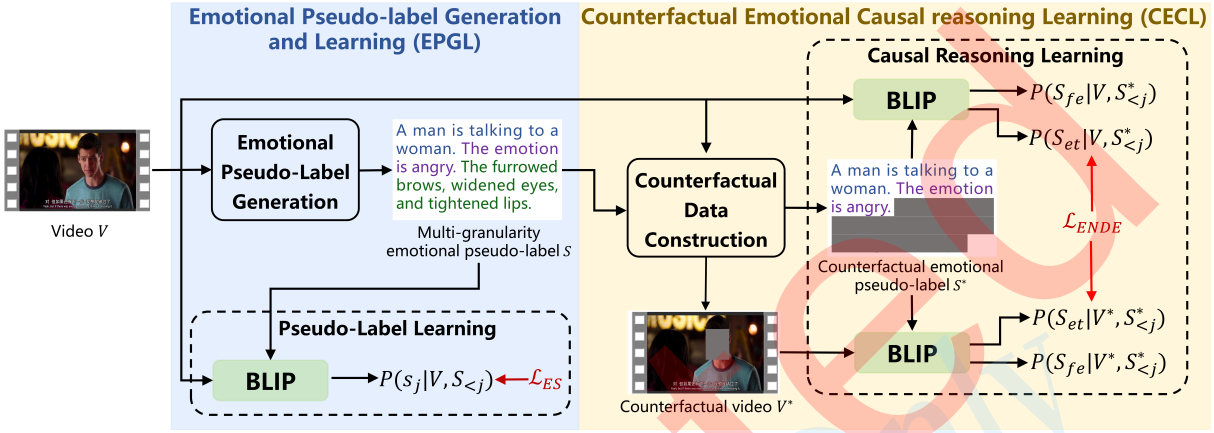


图 2 (网络版彩图) 方法框架图. 我们的 **CECR-BLIP** 通过情感伪标签生成与学习 **EPGL** 和反事实情感因果推理学习 **CECL** 两大模块协同建模, 在生成精细情感描述的同时有效缓解了生成中的情感幻觉问题. 整体框架中共使用三个 **BLIP** 实例: 一个 **BLIP** 用于伪标签学习阶段; 另外两个 **BLIP** 共享模型参数, 仅在输入视频条件上存在差异, 以对比仅在输入不同的情况下的情感输出差异, 从而实现对情感因果效应的显式建模

Figure 2 (Color online)Framework of our method. Our CECR-BLIP employs a collaborative modeling framework consisting of Emotional Pseudo-label Generation and Learning (EPGL) module and Counterfactual Emotional Causal reasoning Learning (CECL) module, which not only facilitates the generation of fine-grained emotional description but also effectively mitigates emotional hallucination in the generation process. The overall framework employs three BLIP instances: one is used for the pseudo-label learning stage, while the other two instances share model parameters and differ only in their input videos. This design enables a direct comparison of emotion outputs under different input conditions, thereby allowing explicit modeling of emotional causal effects

3.3 情感伪标签生成与学习 EPGL

为了提升 BLIP 对细粒度情感信息的理解能力, 我们设计了一个情感伪标签生成与学习模块 EPGL, 该模块旨在为每个视频构建**多粒度情感伪标签** S 并引入情感语义描述损失以引导模型学习情感信息, 最终生成精细的情感描述.

为全面刻画视频中的情感语义, EPGL 首先从三个维度生成多粒度情感伪标签 S: 全局内容描述 S_{ct}, 全局情感描述 S_{et} 和人脸表情描述 S_{fe}, 公式化为 $S = S_{ct} + S_{et} + S_{fe}$. S 的生成步骤如图3所示. 具体而言, 对于每个训练样本, 首先将视频 V 输入冻结的 BLIP 以生成全局内容描述 $S_{ct} = BLIP(V)$. 其次, 在情感类别标签 *Label* (如 angry, happy 等) 上引入固定文本提示 “The emotion is {}”, 生成全局情感描述 S_{et} =“ The emotion is *Label* ”. 然后, 我们在 GPT-4 中输入指令 “Please generate descriptive sentences for facial action units related to *Label*”, 生成与该 *Label* 对应的人脸表情描述 S_{fe}. 通过上述步骤, EPGL 为每个训练样本生成了多粒度情感伪标签 S.

为了进一步强化 BLIP 对情感语义的理解能力, EPGL 引入了情感语义描述损失 (Emotional Semantic Description Loss, $\mathcal{L}_{ES}$) 对模型进行训练. 具体而言, EPGL 首先将视频 V 与多粒度情感伪标签 S 一同输入 BLIP, 生成预测文本序列 S_{pred}. 随后, 通过最小化交叉熵损失来度量 S_{pred} 与 S 之间的词级匹配程度, 从而引导模型以自回归的方式最大化生成序列的条件概率. $\mathcal{L}_{ES}$ 的公式如下:

$$\mathcal{L}_{ES} = -\sum_{j=1}^{|S_{pred}|} \log P(s_j|V, S_{<j}), \tag{3}$$

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

其中 $|S_{pred}|$ 表示 S_{pred} 的长度, s_j 为 S_{pred} 中的第 j 个词, $S_{<j}$ 表示第 j 个词之前生成的所有词, $P(s_j|V, S_{<j})$ 表示模型在输入已经生成的词 $S_{<j}$ 和视频 V 的条件下生成当前单词的概率分布. 经过 EPGL 模块的学习, BLIP 具备了情感语义理解能力, 并且能够生成包含情感信息的描述.

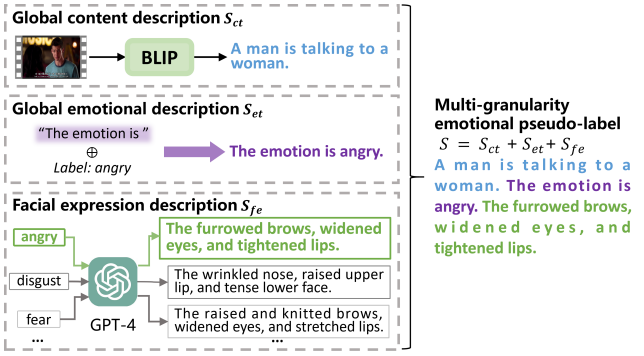


图 3 (网络版彩图) 情感伪标签生成. 通过分别生成全局内容描述 S_{ct}, 全局情感描述 S_{et} 与人脸表情描述 S_{fe}, 最终融合得到多粒度情感伪标签 S

Figure 3 (Color online)Emotional pseudo-label generation. Multi-granularity emotional pseudo-label S are obtained by respectively generating global content description S_{ct}, global emotional description S_{et}, and facial expression description S_{fe}, followed by fusion



图 4 (网络版彩图) 反事实数据构造. 通过遮挡视频 V 中的人脸和多粒度情感伪标签 S 中的人脸表情描述 S_{fe}, 得到反事实视频 V^* 与反事实情感伪标签 S^*

Figure 4 (Color online)Counterfactual data construction. By masking the face in the video V and the S_{fe} in the Multi-granularity emotional pseudo-label S, we obtain the counterfactual video V^* and counterfactual emotional pseudo-label S^*

3.4 反事实情感因果推理学习 CECL

为缓解 BLIP 在描述生成过程中易出现的情感幻觉问题, 我们进一步提出反事实情感因果推理学习模块 CECL, 该模块包括: 反事实数据构造, 视频情感描述因果图构造和情感自然直接效应优化. 首先, 反事实数据构造旨在生成反事实样本, 为后续的反事实因果推理提供数据支撑. 其次, 视频情感描述因果图构造通过建立视频与反事实视频及其情感伪标签之间的因果关系, 以区分直接与间接路径, 为后续因果效应建模提供结构支撑. 最后, 情感自然直接效应优化基于自然直接效应 (Natural Direct Effect, NDE) 并结合情感标签进行监督, 设计情感自然直接效应损失 (Emotional Natural Direct Effect Loss, $\mathcal{L}_{ENDE}$), 以约束模型在生成过程中对虚假情感关联的依赖, 从而缓解情感幻觉问题. 通过联合优化损失 $\mathcal{L}_{ENDE}$ 与情感语义描述损失 $\mathcal{L}_{ES}$, 模型能够生成精细且准确的情感描述.

3.4.1 反事实数据构造

在本节中, CECL 旨在通过分别构建反事实视频与反事实情感伪标签, 为情感词生成与视觉特征之间的因果建模提供数据基础. 通过这种方式, 模型能够在缺乏人脸表情等情感线索时仍保持合理的情感词生成, 减少对特定视觉区域的依赖, 从而有效缓解情感幻觉问题.

为实现上述目标, CECL 设计了基于遮盖 (mask) 操作的反事实样本生成策略, 如图4所示. 对于视频 V, CECL 利用 MTCNN [30] 检测视频帧中的人脸区域, 并对检测到的区域进行遮盖以获得反事实视频 V^*. 对于多粒度情感伪标签 S, CECL 移除其中的人脸表情描述 S_{fe} 以构建反事实情感伪标签 S^*. 通过对视觉与文本双模态的反事实构造, CECL 为后续的反事实因果推理提供了数据支撑.

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

3.4.2 视频情感描述因果图构造

在本节中, CECL 旨在通过构建因果图来刻画视频特征与情感词生成之间的因果关系, 从而明确视频内容在情感描述生成过程中产生的影响. 具体而言, 视频输入对生成的情感词存在两条主要因果路径: 一是直接路径, 即视频内容直接影响情感语义的表达; 二是间接路径, 即视频的情感特征影响已经生成的描述, 从而间接作用于当前词的生成. 该设计能够同时保留视觉特征对情感表达的直接影响, 并捕捉情感随时间变化的动态依赖关系, 从而兼顾细粒度情感识别和描述的连贯性.

为清晰刻画这两条路径并强化直接路径以缓解情感幻觉, CECL 构建了视频情感描述的因果图. 图5展示了我们设计的三种因果图: (a) 表示事实情境下, 原因变量 X 为视频 V, 中介变量 M 表示模型在 V 的影响下生成的词序列 $S_{<j}$, 输出结果为 $Y_{V,S_{<j}}$ (即 s_j); (b) 表示反事实情境下, 输入为反事实视频 V^*, 中介变量 M 表示模型在 V^* 的影响下生成的词序列 $S^*_{<j}$, 输出为 $Y_{V^*,S^*_{<j}}$ (即 s^*_j); (c) 表示混合情境下, 输入为视频 V 但中介变量表示在受反事实视频 V^* 影响下生成的词序列 $S^*_{<j}$, 输出为 $Y_{V,S^*_{<j}}$ (即 s'_j). 其中, s_j, s^*_j 与 s'_j 分别表示在不同输入条件下生成的情感词.

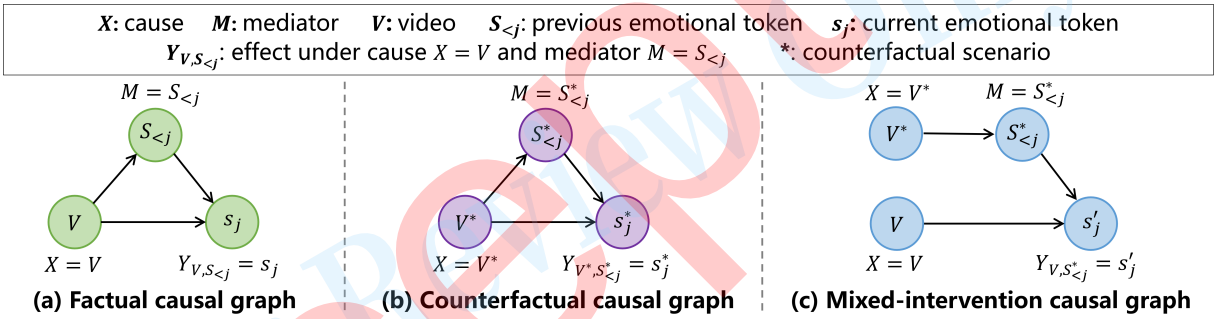


图 5 (网络版彩图) 视频情感描述中的情感因果图. (a) 以视频和多粒度情感伪标签为输入, 输出情感词 s_j; (b) 以反事实视频和反事实情感伪标签为输入, 输出情感词 s^*_j; (c) 以视频和反事实情感伪标签为输入, 输出情感词 s'_j

Figure 5 (Color online)Causal graphs for video emotional description. (a) Given the video and multi-granularity emotional pseudo-label as input, the model generates the emotional word s_j; (b) Given the counterfactual video and counterfactual emotional pseudo-label as input, the model generates the emotional word s^*_j; (c) Given the video and counterfactual emotional pseudo-label as input, the model generates the emotional word s'_j

3.4.3 情感自然直接效应优化

为了缓解模型生成描述中的情感幻觉问题, CECL 在本节中引入因果效应中的自然直接效应 NDE 进行因果建模, 旨在分离视频中情感特征对生成描述的直接影响与间接影响, 并强化前者以提升情感预测的准确性. 在因果理论 [31] 中, 因果效应包括总效应 (Total Effect, TE), 自然直接效应 (NDE) 与总间接效应 (Total Indirect Effect, TIE), 满足 $TE = NDE + TIE$. 由于视觉情感特征对生成词的直接影响对生成描述质量至关重要, 而间接影响路径中的中介变量 (已生成的词) 可能由于共现频率而引入虚假相关. 为此, CECL 在 BLIP 框架中引入 NDE, 并利用情感标签进行指导, 从而抑制由词与词之间的频繁共现而产生的虚假相关, 以缓解情感幻觉问题. 在反事实因果推理框架下, NDE 用于刻画在固定中介变量取值的情况下, 原因变量对结果变量的直接影响. 其标准定义为:

$$NDE_{x,x^*} = E[Y_{x,M_{x^*}}] - E[Y_{x^*}]. \tag{4}$$

为了估计 NDE, CECL 构建了两种干预情境: 如图5(b) 所示, 反事实输入 (V^*, $S^*_{<j}$) 表示原因和中介变量均取自反事实条件, 用于获得反事实输出 $Y_{V^*,S^*_{<j}}$; 如图5(c) 所示, 混合干预输入 (V, $S^*_{<j}$) 则固定中介变量输入 $S^*_{<j}$ 不变, 仅将原因输入由反事实视频 V^* 替换为视频 V. 二者输出差异反映了视频输入在相同中介条件

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

下对当前生成词的直接影响, 而避免了间接影响路径中已经生成的词对当前生成词产生的虚假关联. 这使模型能够更专注于学习视觉特征与情感词之间的因果关系. 通过比较两种情境下的输出, 可以估计视频输入 V 与 V^* 对生成词的自然直接效应 NDE_{V,V^*}, 公式如下:

$$NDE_{V,V^*} = E[Y_{V,S^*_{<j}}] - E[Y_{V^*}]. \tag{5}$$

进一步, 本文遵循 Pearl [32] 的可辨识性准则作出以下因果假设: (1) 在给定原因输入 X 后, 中介变量 M 与输出 Y 条件独立, 即 $Y_{X,M} \perp M|X = V$. (2) 在给定原因输入 X 后, 观测到的输出 Y 等于潜在结果 $Y_{X=V}$, 即 $Y = Y_{X=V}$. (3) 潜在结果 $Y_{V,S_{<j}}$ 与反事实中介值 $S^*_{<j}$ 满足条件独立性, 即 $Y_{V,S_{<j}} \perp S^*_{<j}$. 基于以上假设, 可以得到最终的 NDE_{V,V^*}, 公式如下:

$$NDE_{V,V^*} = \frac{1}{|S^*|}\sum_{j=1}^{|S^*|}(Y_{V,S^*_{<j}} - Y_{V^*,S^*_{<j}}), \tag{6}$$

其中 $Y_{V,S^*_{<j}}$ 表示将视频 V 与已生成的反事实情感词 $S^*_{<j}$ 输入 BLIP 后的输出结果 (对应图5(c)), $Y_{V^*,S^*_{<j}}$ 则表示将反事实视频 V^* 与已生成的反事实情感词 $S^*_{<j}$ 输入 BLIP 后的输出结果 (对应图5(b)). 值得注意的是, 由于在 V^* 中仅遮挡了人脸区域, 视频的整体情感不会发生改变, 因此两种条件下的全局情感描述应保持一致. 为此, 我们额外利用情感类别标签进行监督.

为了最大化 NDE_{V,V^*}, 我们通过最小化自然直接效应损失 $\mathcal{L}_{NDE}$ 来实现. 考虑到所构造的反事实干预在理论上仅影响人脸表情描述 S_{fe} 的生成, 故我们将损失计算限定于该子序列. 此外, 为保证两种条件下的全局情感描述保持一致, 我们进一步引入情感类别损失 $\mathcal{L}_{Emo}$ 作为监督. 公式如下:

$$\mathcal{L}_{NDE} = -\sum_{i=1}^{|S_{fe}|}[\frac{1}{|S^*|}\sum_{j=1}^{|S^*|}\big(\log P(S_{fe_i}|V, S^*_{<j}) - \log P(S_{fe_i}|V^*, S^*_{<j})\big)], \tag{7}$$

$$\mathcal{L}_{Emo} = \sum_{k=1}^{|S_{et}|}[\log P(S_{et_k}|V, S^*_{<p+k}) - \log P(S_{et_k}|V^*, S^*_{<p+k})], \tag{8}$$

其中, $|\cdot|$ 表示生成描述的长度, S_{fe_i} 表示人脸表情描述 S_{fe} 中的第 i 个词, p 表示全局情感描述 S_{et} 在 S 中出现的第一个词的位置, $P(S_{fe_i}|V, S^*_{<j})$ 和 $P(S_{et_k}|V, S^*_{<p+k})$ 分别表示在视频 V 与已经生成的反事实情感词的输入下生成当前人脸表情词和当前全局情感词的概率分布. $\mathcal{L}_{NDE}$ 表示我们希望在视频 V 和反事实情感伪标签输入下生成 S_{fe} 的概率越大, 而在反事实视频和反事实情感伪标签下生成的概率越小, 由于 S_{fe} 不一定会出现在 S^* 中, 故使用平均值来估计其在 S^* 中的概率; $\mathcal{L}_{Emo}$ 表示我们希望通过情感标签进行监督, 确保两种情况下生成的全局情感描述 S_{et} 是一致的.

综上所述, 我们设计了两个相辅相成的优化目标: $\mathcal{L}_{NDE}$ 用于最大化 NDE_{V,V^*} 以捕捉视觉与情感间的因果关系, $\mathcal{L}_{Emo}$ 通过情感类别监督保证 S_{et} 的一致性. 最终, $\mathcal{L}_{ENDE}$ 由二者共同组成:

$$\mathcal{L}_{ENDE} = \mathcal{L}_{NDE} + \mathcal{L}_{Emo}. \tag{9}$$

3.5 总体优化目标

在我们的 CECR-BLIP 中, 总体优化目标是情感语义描述损失 $\mathcal{L}_{ES}$ 与情感自然直接效应损失 $\mathcal{L}_{ENDE}$ 的总和. 因此, 总体优化目标公式如下:

$$\mathcal{L} = \mathcal{L}_{ES} + \alpha\mathcal{L}_{ENDE}, \tag{10}$$

其中, α 为 $\mathcal{L}_{ENDE}$ 的权重超参数.

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

3.6 推理阶段

在推理阶段, 我们采用训练后的 BLIP 模型以自回归方式生成情感描述, 旨在输出与视频内容高度相关且情感表达丰富的文本. 如图6所示, 具体而言, 给定一段视频 V', 视觉编码器 φ_V 首先提取其帧序列的视觉情感特征. 随后, 文本解码器 φ_T 在解码标记 ([Decode]) 的触发下, 结合提取到的视觉特征与已生成的文本序列, 逐步预测下一个最有可能的词, 直至遇到生成结束标记 ([EOS]).

通过这一自回归生成过程, BLIP 模型能够在每一步有效融合视频的视觉与情感线索, 从而生成语义连贯, 情感精确的描述文本. 如图6所示, 最终输出的情感描述不仅准确反映了视频的视觉内容, 还能细致刻画其中蕴含的情感信息, 为零样本视频情感描述任务提供了可靠支持.

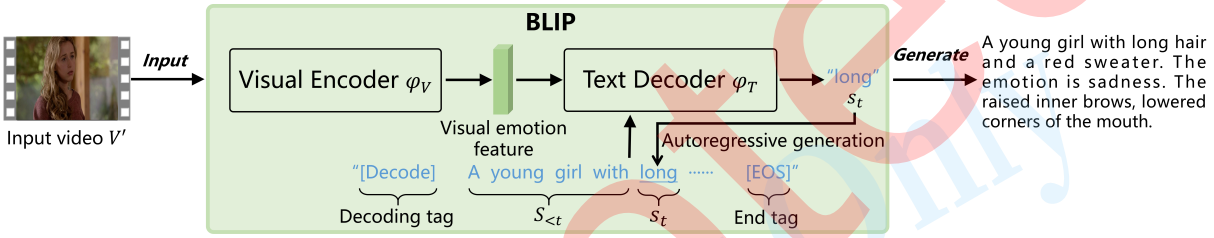


图 6 (网络版彩图)BLIP 的推理阶段. 在推理阶段, BLIP 首先通过视觉编码器提取视觉情感特征, 然后由文本解码器在自回归框架下逐步生成情感描述

Figure 6 (Color online)The inference stage of BLIP. During the inference stage, BLIP first extracts the visual emotion feature through a visual encoder, and then the emotional description is gradually generated by a text decoder in an autoregressive framework

4 实验与分析

4.1 数据集

本研究采用了两个公开的情感视频数据集: DFEW [33] 和 MAFW [10], 以验证模型的有效性和泛化能力, 图7给出了这两个数据集的样本示例.

(1) DFEW 数据集 [33]:

DFEW 是一个大规模动态人脸情感数据集, 包含超过 16,372 个从 1,500 多部电影中提取的视频片段, 涵盖 7 种基本情感类别, 具有真实场景下的复杂光照, 姿态与遮挡变化. 每个视频片段由 10 名专业标注人员独立标注, 确保了标注的准确和可靠性. 但是它并没有人工标注的视频-情感描述对.

(2) MAFW 数据集 [10]:

MAFW 是一个大规模, 多模态, 多标签情感数据集, 包含 11 个单一情感类别 (例如愤怒, 快乐, 悲伤, 惊讶等), 以及 32 个复合情感类别和精细的情感描述性文本. 该数据集含有 10045 个自然场景下的视频音频片段, 为视频提供了关于人脸情感和情绪的中英文双语描述性文本. 这些描述性文本不仅涵盖了视频中的环境信息, 还细致描绘了人物的肢体动作和面部表情变化 (如睁眼, 闭嘴, 嘴角上扬等), 从而为更精确地理解视频所传达的情感提供了丰富的情感信息基础.

4.2 任务设置

根据现有零样本视频描述工作 [18], 我们将零样本视频情感描述分为域内实验和域外实验, 如表1所示.

(1) 域内实验: 通过在 MAFW 数据集的无人工标注描述数据上训练模型, 然后在 MAFW 数据集上进行评估来执行域内实验.

Accepted
For Review Only
https://www.sciengine.com/doi/10.1360/SSI-2025-0435

(2) 域外实验: 通过在 DFEW 数据集的无人工标注描述数据上训练模型, 然后在 MAFW 数据集上进行评估来执行域外实验.

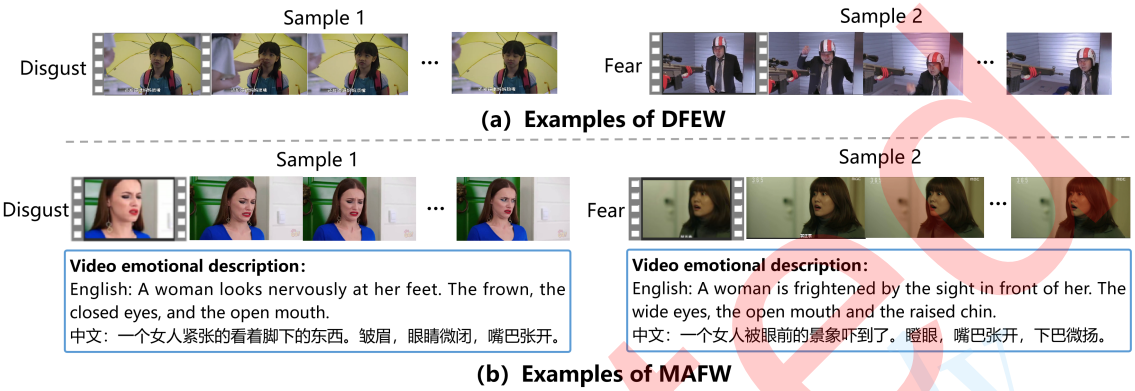


图 7 (网络版彩图)DFEW 和 MAFW 数据集示例

Figure 7 (Color online)Examples of DFEW and MAFW datasets

表 1 零样本视频情感描述任务设置

Table 1 Zero-shot video emotional description task settings

Task settings	Training dataset		Test dataset		Number of emotional categories
	Dataset	Number	Dataset	Number	
In-domain experiments	MAFW	6423	MAFW	1611	10
Out-of-domain experiments	DFEW	7221	MAFW	1289	6

4.3 实验训练细节设置

我们使用 Pytorch 深度学习框架来进行一系列实验. 实验在一台拥有 Intel (R) Xeon (R) Gold 6240C 2.60GHz, 128G 内存和 NVIDIA GeForce RTX 3090 GPU 的 PC 机上进行. 为了进行公平的比较, 本文对比的方法在同样实验环境下进行训练. 具体参数如表2所示.

表 2 CECR-BLIP 方法训练的关键参数

Table 2 Key training parameters of the CECR-BLIP method

Hyperparameter	Settings	Hyperparameter	Settings
Optimizer	SGD	Initial learning rate	0.0001
Weight decay	0.0001	Batch size	1
Training epoch	20	The number of frames selected	4

4.4 评价指标

根据现有的方法 [6,9,18,21], 我们使用四个标准的语义度量来评估我们的方法, 即 BLEU-4 (B-4) [34], METEOR (M) [35], ROUGE-L (R-L) [36] 和 CIDER (C) [37].

BLEU [34] 基于 n-gram 重叠率评估生成文本质量, 引入长度惩罚避免短文本高分, 本文选用 BLEU-4. METEOR [35] 通过同义词和词干匹配放宽条件, 结合精确率和召回率的调和均值, 提升语义评估的全面性和鲁棒性. ROUGE-L [36] 基于最长公共子序列衡量词序一致性和语义连贯性, 对长文本匹配更具优势. CIDER [37] 基于 TF-IDF 加权 n-gram 计算相似度, 关注关键信息与多参考一致性, 适合描述生成任务. 所有指标都与 Microsoft COCO 评估服务器上发布的代码相匹配 [38].

Accepted
For Review Only

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

4.5 域内任务上的实验结果

为了评估我们的 CECR-BLIP 在域内设置下的零样本视频情感描述性能，我们将其与几种最先进的零样本图像/视频描述方法进行了比较，包括 ZeroCap [39]，MAGIC [11]，ZSV2T [20] 以及我们的基线方法 BLIP [14]. 此外，我们也考虑了 CapDec [21] 和 MultiCapCLIP [18] 这两种利用文本标注进行训练的方法以及 InternVL2 [15]，VideoLLaMA3 [40] 和 Qwen2.5-VL [41] 这三种最新的开源多模态大模型. 需要注意的是，尽管 CapDec 和 MultiCapCLIP 并未采用视频-描述对进行训练，但通过学习原始数据集中的语言风格，这两种方法在各项评价指标上取得了较优的性能. 因此，为了更公平地评估 CECR-BLIP 的性能，我们没有将它们作为主要对比方法. 但在后续分析中我们会指出，对于这两种方法 CECR-BLIP 在两个关键评价指标上得到了有竞争力的结果.

实验结果如表3所示 (最优结果以加粗字体展示)，我们的 CECR-BLIP 实现了最优性能. 与基线方法 BLIP 相比，CECR-BLIP 在四个评估指标 (即 BLEU-4, METEOR, ROUGE-L 和 CIDER) 上分别实现了 159.49%, 107.47%, 37.03% 和 71.01% 的相对提升. 这证明了我们的方法让 BLIP 模型获得了生成情感描述的能力，而无需依赖人工标注的视频-情感描述对.

对于前文提到的 CapDec 和 MultiCapCLIP 方法，CECR-BLIP 在 METEOR 和 ROUGE-L 上与 CapDec 相比得到了 61.46%, 19.32% 的相对提升，同时也取得了与 MultiCapCLIP 相比有竞争力的结果，这进一步证明了 CECR-BLIP 的优越性. METEOR 和 ROUGE-L 都是衡量语义相似性的指标，这表明 CECR-BLIP 不仅在语义匹配和生成质量上具有优越性，还在多样性方面具有优势.

对于前文提到的三个多模态大模型，我们在推理阶段直接添加提示 “Describe the basic content and emotional information of this video” 进行生成. 从评价指标可以看出，仅依赖提示进行直接推理虽能生成情感描述，但往往缺乏精细性，并伴随较多的幻觉现象，因而整体表现不佳. 这一结果进一步凸显了本文所提出的方法的必要性与价值.

这些结果表明，CECR-BLIP 在零样本视频情感描述任务中可以有效地捕获视频中的关键情感信息，在不依赖人工标注的视频-情感描述对的情况下，能够生成更准确，更具情感语义一致性的描述. 这些优势为 CECR-BLIP 在实际应用中提供了有力支持.

表 3 域内设置下 MAFW 训练和测试的结果

Table 3 Results of training and testing on MAFW in the in-domain setting

Method type	Method	Training with raw data		Evaluation metrics(%)			
		Video data	Text data	B-4 ↑	M ↑	R-L ↑	C ↑
Training-Free	ZeroCap [39]	✗	✗	0	3.15	11.86	0.90
	MAGIC [11]	✗	✗	0	3.09	12.47	0.58
	ZSV2T [20]	✗	✗	0.24	5.17	15.93	3.10
	BLIP [14]	✗	✗	0.79	7.23	22.90	3.38
	InternVL2-2B [15]	✗	✗	0.9	12.09	20.48	0
	VideoLLaMA3-2B [40]	✗	✗	0.58	10.99	21.58	0.62
	Qwen2.5-VL-3B [41]	✗	✗	0.56	10.82	19.13	0
With text annotations	CapDec [21]	✗	✓	2.89	9.29	26.30	11.39
	MultiCapCLIP [18]	✗	✓	6.69	12.96	31.39	23.68
With videos and emotional labels	**Our CECR-BLIP**	✓	✗	**2.05**	**15.00**	**31.38**	**5.78**

4.6 域外任务上的实验结果

为了评估 CECR-BLIP 在域外设置下的零样本视频情感描述的性能，我们将 CECR-BLIP 与几种无需文本训练的零样本视频描述方法进行了比较，包括 ZeroCap [39]，MAGIC [11]，ZSV2T [20] 以及我们的基线方法 BLIP [14]. 同时，也与最新的三个多模态大模型 InternVL2 [15]，VideoLLaMA3 [40] 和 Qwen2.5-VL [41] 进行了比

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

较. 如表4所示, 我们的方法实现了最优性能, 在多个指标上都有显著提升.

与基线方法 BLIP 相比, CECR-BLIP 在 BLEU-4, METEOR, ROUGE-L 和 CIDER 上分别实现了 150.55%, 113.08%, 41.21% 和 89.38% 的相对提升. 这是由于这些方法在零样本场景下缺乏对情感信息的有效建模, 它们仅关注视频内容, 这进一步验证了 CECR-BLIP 在情感描述上的优势. 此外, 前面提到的多模态大模型仍存在着生成的情感描述不够精细, 幻觉严重等问题, 导致指标得分低. 尽管在域外设置中训练集和测试集来自不同的数据集, 但 CECR-BLIP 仍可以准确捕获视频中的关键情感信息, 并生成精准的情感描述, 证明了我们的方法具备实际应用中所需的泛化性能.

表 4 域外设置下 DFEW 训练 MAFW 测试的结果

Table 4 Results of training on DFEW and testing on MAFW in the out-of-domain setting

Method	Evaluation metrics(%)			
	B-4 ↑	M ↑	R-L ↑	C ↑
ZeroCap [39]	0	3.16	11.78	0.88
MAGIC [11]	0	3.05	12.46	0.59
ZSV2T [20]	0.26	5.14	15.91	3.19
BLIP [14]	0.91	7.11	22.76	3.20
InternVL2-2B [15]	0.92	12.08	20.52	0
VideoLLaMA3-2B [40]	0.42	10.76	21.37	0.43
Qwen2.5-VL-3B [41]	0.55	10.78	19.11	0
Our CECR-BLIP	**2.28**	**15.15**	**32.14**	**6.06**

4.7 消融性实验与分析

4.7.1 不同模块的消融研究

为了更全面的分析 CECR-BLIP 中不同模块的效果, 我们进行了模块消融实验, 结果如表5所示. 其中, 第一行是 CECR-BLIP 的结果, 第二行是去掉反事实情感因果推理学习模块 (CECL) 的结果, 第三行是同时去掉反事实情感因果推理学习模块和情感伪标签生成与学习模块 (EPGL) 的结果.

域内设置上的模块消融研究. 从结果上看, 在加入 EPGL 后, 模型在各项指标上取得了显著提升, 这表明我们的多粒度情感伪标签能够为模型提供有效的监督, 从而增强其对情感语义的理解能力. 在引入 CECL 后, 各项指标得到了进一步的提升. BLEU-4 和 METEOR 的相对提升幅度较为明显, 而这两项指标主要衡量生成描述与真实描述之间的匹配程度. 这表明经过反事实因果推理优化后, 模型能够生成与真实描述更加一致的句子, 从而有效缓解了生成过程中的幻觉问题.

域外设置上的模块消融研究. 与域内实验结果相似, 在域外设置下我们的多粒度情感伪标签仍能够有效指导模型生成质量较高的描述. 在引入 CECL 后, 各项指标的提升更加明显. 这说明在域外设置中, 由于视频数据具有多样性和复杂性, 生成的伪标签本身仍可能包含噪声和虚假相关, 而因果推理通过建模因果效应削弱了这些虚假相关的影响, 使模型更专注于视频中人物的情感表达.

表 5 在域内与域外实验设置下的模块消融实验结果

Table 5 Ablation study results of different modules under in-domain and out-of-domain experimental settings

Method	**In-domain setting**				**Out-of-domain setting**			
	B-4 ↑	M ↑	R-L ↑	C ↑	B-4 ↑	M ↑	R-L ↑	C ↑
CECR-BLIP	**2.05**	**15.00**	**31.38**	**5.78**	**2.28**	**15.15**	**32.14**	**6.06**
w/o CECL	1.91	14.29	31.18	5.55	1.95	12.82	29.33	5.66
w/o CECL and EPGL	0.79	7.23	22.90	3.38	0.91	7.11	22.76	3.20

综上所述, 无论在域内还是域外实验中, 所设计的各个模块均对模型性能有显著贡献. EPGL 模块为模型

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

提供了高质量的训练标签, 从而显著增强了模型对情感语义的理解能力. 而 CECL 模块则通过因果建模削弱了样本间的虚假关联, 有效缓解了生成过程中的情感幻觉问题.

4.7.2 不同因果效应的消融研究

为了更全面地分析 CECR-BLIP 的有效性, 我们比较了两种因果效应的影响: 总效应 (TE) 和自然直接效应 (NDE). 首先, 我们简要介绍一下 TE. 如图5(a) 与图5(b) 所示, TE 用于衡量事实输入 (V, $S_{<j}$) 与反事实输入 (V^*, $S^*_{<j}$) 下的输出结果之间的差异. TE 同时考虑了视频内容通过直接路径产生的影响, 以及经由中介变量 (已生成的词) 产生的间接影响. 通过比较这两种情境下的输出结果, 可以估计视频 V 和 V^* 对生成词的总效应 TE_{V,V^*}, 公式如下:

$$TE_{V,V^*} = \frac{1}{|S|}\sum_{j=1}^{|S|} Y_{V,S_{<j}} - \frac{1}{|S^*|}\sum_{j=1}^{|S^*|} Y_{V^*,S^*_{<j}}, \tag{11}$$

其中 $Y_{V,S_{<j}}$ 表示将视频 V 与已生成的情感词 $S_{<j}$ 输入 BLIP 后的输出结果, $Y_{V^*,S^*_{<j}}$ 则表示将反事实视频 V^* 与已生成的反事实情感词 $S^*_{<j}$ 输入 BLIP 后的输出结果. 我们希望通过最大化 TE_{V,V^*} 以提升事实输入条件下输出人脸表情描述 S_{fe} 的概率, 而降低反事实输入条件下输出 S_{fe} 的概率, 与公式 (7) 相似, 我们通过最小化总效应损失 $\mathcal{L}_{TE}$ 来实现, 公式如下:

$$\mathcal{L}_{TE} = -\sum_{i=1}^{|S_{fe}|}[\log P(S_{fe_i}|V, S_{<p+i}) - \frac{1}{|S^*|}\sum_{j=1}^{|S^*|}\log P(S_{fe_i}|V^*, S^*_{<j})], \tag{12}$$

其中, $|\cdot|$ 表示生成描述的长度, p 表示人脸表情描述 S_{fe} 中第一个词的位置索引, S_{fe_i} 表示人脸表情描述 S_{fe} 中的第 i 个词, $P(S_{fe_i}|V, S_{<p+i})$ 表示在视频 V 与已经生成的情感词 $S_{<p+i}$ 的输入下生成当前人脸表情词的概率分布.

域内设置上不同因果效应的消融研究. 结果如表6所示, TE 和 NDE 在不同指标上各具优势. 具体而言, TE 在 BLEU-4 和 METEOR 两个指标上表现较优, 而这两个指标主要衡量生成描述与真实描述在词汇和语义层面的匹配程度. 这表明 TE 通过建模所有可能的因果路径来优化模型, 以提升描述生成质量. 相比之下, NDE 在 ROUGE-L 和 CIDER 上取得更佳表现. ROUGE-L 反映语义连贯性和词序一致性, 而 CIDER 侧重于关键信息的捕捉. 这表明 NDE 通过强化视频输入对生成描述的直接影响, 降低了已生成文本产生的影响, 从而降低了因虚假情感关联导致的描述偏差.

域外设置上不同因果效应的消融研究. 结果如表6所示, TE 和 NDE 在各项评价指标上的表现存在细微差异, 其中 NDE 的效果更优. 由于域外视频数据具有多样性和复杂性, TE 通过建模所有可能的因果路径来优化整体性能的方式可能在中介变量 (已生成文本) 不可靠时引入额外噪声. 相比之下, NDE 聚焦于视频输入对生成结果的直接影响, 有效削弱了中介变量带来的干扰. 这使模型在面对域外数据的不确定性时, 能更准确地捕捉视频内容的核心语义, 并生成更具一致性的情感描述.

表 6 在域内与域外实验设置下 TE 与 NDE 的影响

Table 6 Impact of TE and NDE under in-domain and out-of-domain experimental settings

Method	In-domain setting				Out-of-domain setting			
	B-4 ↑	M ↑	R-L ↑	C ↑	B-4 ↑	M ↑	R-L ↑	C ↑
TE	**2.08**	**15.14**	31.13	5.56	2.24	**15.24**	32.07	6.01
NDE	2.05	15.00	**31.38**	**5.78**	**2.28**	15.15	**32.14**	**6.06**

综上所述, 在域内设置中, 优化 TE 有助于提升视频描述与内容的情感契合和识别准确性, 优化 NDE 则

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

有助于直接因果建模, 抑制干扰信息. 在域外设置中, TE 综合所有因果路径, 适合需要综合权衡的任务, NDE 则因其聚焦于直接因果路径, 在情感描述等要求精确的场景下更具优势.

4.7.3 情感自然直接效应损失 $\mathcal{L}_{ENDE}$ 的权重超参数 α 的影响

在 CECR-BLIP 中, 情感自然直接效应损失 $\mathcal{L}_{ENDE}$ 的权重由超参数 α 控制. 我们在域内与域外两种实验设置下系统分析了不同权重取值对模型性能的影响, 并据此总结出最优权重的选择依据.

域内设置下 α 的影响. 为了更直观地展示损失权重与模型性能之间的关系, 我们采用折线图呈现实验结果. 我们测试了不同 α 取值在 METEOR 上的表现, 如图8(a) 所示. 实验结果表明, 随着 α 的增大, 模型性能呈现出先上升后下降的趋势. 具体而言, 从 α=0.2 到 α=0.6, METEOR 从 14.61% 逐步提升至 15.00%, 这表明在这一区间内, 较高的权重能使模型更加专注于直接因果路径的优化, 从而更好地捕捉关键信息并保持情感一致性. 然而, 当 α 一步增加到 0.7 时, METEOR 下降至 14.63%, 这表明过高的权重可能导致模型对直接因果关系的过度依赖, 从而忽视了其他潜在的因素.

域外设置下 α 的影响. 与域内设置相似, 我们测试了不同 α 取值在 METEOR 上的结果, 如图8(b) 所示. 实验结果显示, 随着 α 的增大, 模型在域外设置上的表现呈现出先上升后下降的规律. 具体来看, 当 α 从 0.2 增加到 0.4 时, 评价指标 METEOR 从 15.09% 逐步提升至 15.15%. 这一趋势表明, 在域外数据上, 优化直接因果路径仍然对模型性能具有积极作用. 然而, 当 α 继续增大到 0.5 和 0.6 时, METEOR 值持续下降. 这说明在域外设置下, 数据分布和特征可能与训练数据存在差异, 过度强调直接因果路径可能会削弱模型对多样化信息的捕捉能力, 从而影响其泛化性能.

综上所述, 在域内设置下, 当 α=0.6 时, 模型在关键信息生成和情感一致性方面表现最优, 这表明该权重值能够有效平衡直接因果路径的优化与情感一致性的保持. 在域外设置下, α=0.4 时模型表现达到最优, 此时模型能够在直接因果路径优化与多样化信息捕捉之间取得较好的平衡.

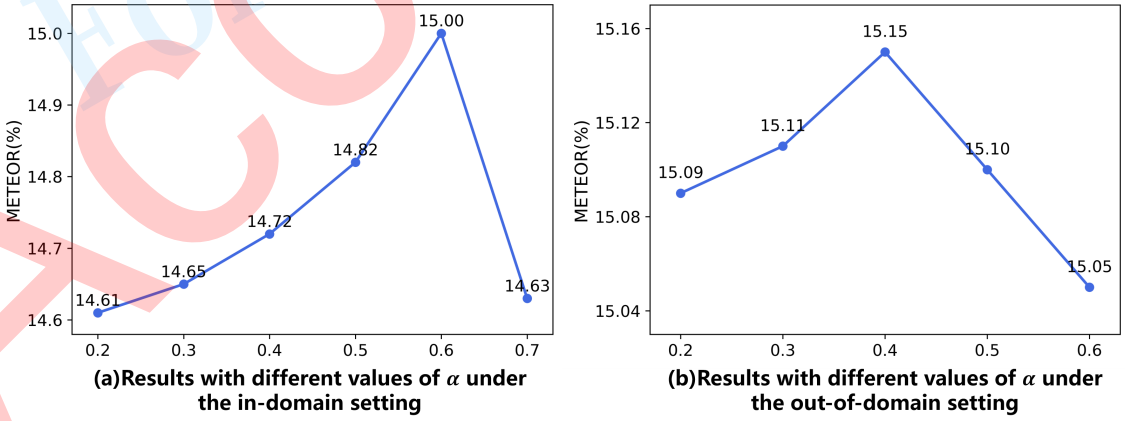


图 8 (网络版彩图) 超参数 α 不同取值对模型性能的影响

Figure 8 (Color online)The impact of different values of hyperparameter α on model performance

4.8 情感幻觉的定量分析

为更直观、系统地评估模型在情感幻觉问题上的表现, 本文进一步引入情感幻觉的定量分析, 以量化所提出 CECL 模块的实际贡献. 具体而言, 我们从两个方面对情感幻觉现象进行评估: (1) 不同情感类别上的识别精度变化, 用于分析 CECL 对各类情感识别能力的影响. (2) 情感幻觉率, 用于衡量模型生成结果中情感描述与真实情感描述不一致的样本占比.

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

对于不同情感类别的识别精度变化，如图9和10所示．在引入 CECL 模块后，无论是在域内还是域外设置下，模型在多个情感类别的识别准确率均实现了显著提升，验证了该模块在增强情感识别性能方面的有效性．同时可以观察到，尽管部分类别的识别准确率仍然较低，甚至在个别情感类别上出现识别率为零的情况，但这主要源于相关情感类别在训练集中可用样本数量有限，模型难以充分学习到稳定且具有判别性的情感表征，从而导致识别性能受限．

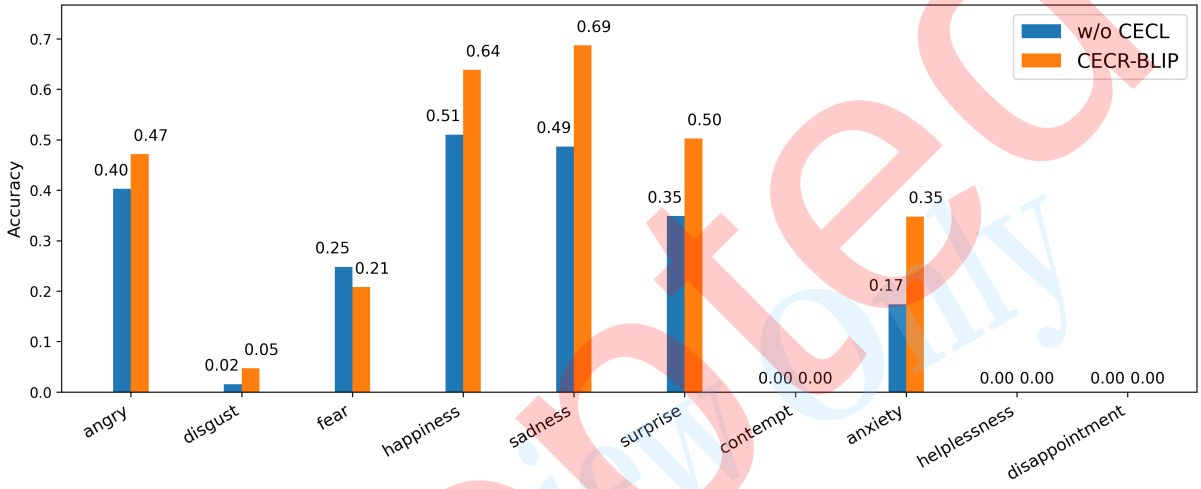


图 9 (网络版彩图) 域内设置下情感识别准确率

Figure 9 (Color online)Accuracy rate of emotion recognition under in-domain setting

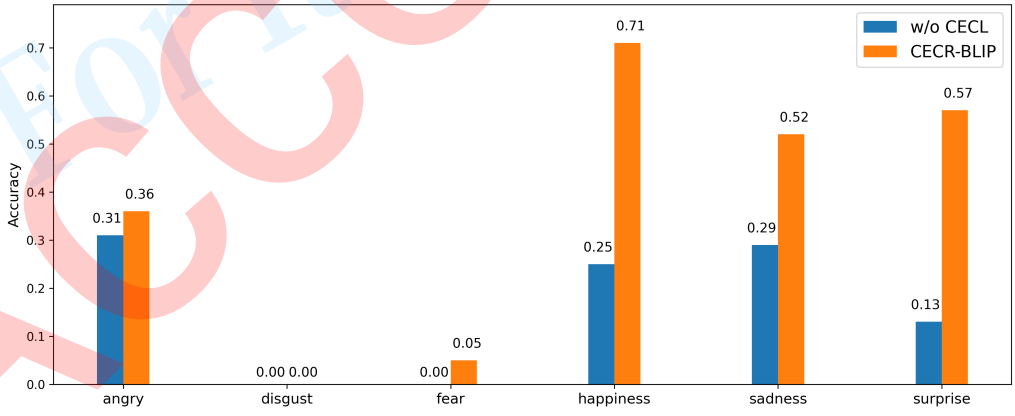


图 10 (网络版彩图) 域外设置下情感识别准确率

Figure 10 (Color online)Accuracy rate of emotion recognition under out-of-domain setting

对于情感幻觉率的评估，我们基于前人提出的 $CHAIR$ [42] 指标，设计了一个适用于情感描述任务的指标 $CHAIR_{emo}$．具体而言，$CHAIR$ 指标包括两个版本，分别从句子层面和幻觉词占比层面评估生成内容中的幻觉，如公式 (13) 所示:

$$CHAIR_s = \frac{|\{\text{sentences with hallucinated object}\}|}{|\{\text{all sentences}\}|}, CHAIR_i = \frac{|\{\text{hallucinated objects}\}|}{|\{\text{all objects mentioned}\}|}. \quad (13)$$

考虑到情感描述任务的复杂性，我们在 $CHAIR$ 的基础上引入语义相似度机制，以缓解同义词与近义词带来的匹配偏差，并同时从句子层面幻觉判定与幻觉情感词占比两个视角对生成结果进行评估．设生成序列和真实序列分别为 $G = \{G_i\}$, $R = \{R_i\}$ $(i = 1, 2, ..., N)$，其中 N 为样本数量．

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

首先, 从生成描述与真实描述中提取人脸表情描述 (AU 序列), 记为 $g_i = \{g_i^j\}$, $r_i = \{r_i^j\}$, 其中 g_i^j 和 r_i^j 分别代表第 i 条生成与参考描述中的第 j 个 AU 描述. 每条生成 AU 的幻觉程度定义为:

$$h(g_i^j) = 1 - \max_{k=1,2,\ldots,|r_i|} Sim(g_i^j, r_i^k), \tag{14}$$

其中, $Sim(g_i^j, r_i^k)$ 用于评估生成的 AU 描述与真实的 AU 描述之间的相似度, 我们用相似度来衡量生成 AU 发生幻觉的比例, 相似度越高则幻觉率越低. 进而可以计算每条情感描述的情感幻觉率, 并对所有样本取平均得到整体幻觉率. 需要注意的是, 在我们的定义中, 生成描述的情感类别是否正确也会计入幻觉计算, 因此每条描述的幻觉率定义为:

$$H(G_i, R_i) = \frac{1}{1 + |g_i|}\left(\sum_{j=1}^{|g_i|} h(g_i^j) + c\right), \tag{15}$$

其中 c 表示情感类别是否一致, 一致则为 0, 否则为 1. 最终的整体情感幻觉率为:

$$CHAIR_{emo} = \frac{1}{N}\sum_{i=1}^{N} H(G_i, R_i). \tag{16}$$

实验结果如表 7 所示, 引入 CECL 模块后, 无论是域内还是域外场景, 模型整体情感幻觉发生比例均显著下降. 这表明该模块通过显式建模情感因果关系并约束生成路径, 能够有效抑制情感描述中的错误推断, 在保持描述质量的同时, 有效提升了情感判别的鲁棒性, 从而验证了其在缓解情感幻觉问题上的有效性.

表 7 域内与域外设置下情感幻觉率的定量分析

Table 7 Quantitative analysis of emotional hallucination rates under in-domain and out-of-domain settings

Method	In-domain setting	Out-of-domain setting
	$CHAIR_{emo} \downarrow$	$CHAIR_{emo} \downarrow$
w/o CECL	46.18	48.79
Our CECR-BLIP	**42.16**	**43.24**

4.9 情感描述伪标签稳定性分析

鉴于 GPT-4 等大模型在生成过程中不可避免地引入一定随机性, 其生成的情感伪标签在质量与稳定性方面仍有必要进行系统性验证. 为增强本文方法在情感伪标签监督条件下的可靠性论证, 本文从伪标签质量评估与生成稳定性分析两个方面, 对基于 GPT-4 生成的情感伪标签进行了定量分析. 具体而言, 我们在 MAFW 训练集中随机选取 500 个视频样本作为分析对象, 以保证评估结果具有统计一致性. 针对生成的情感伪标签质量, 我们采用 BLEU、METEOR、ROUGE-L 和 CIDER 四种常用的自动化评估指标进行衡量, 并进一步通过统计各评估指标在不同视频样本维度上的标准差, 刻画模型在样本层面的生成稳定性. 此外, 为进一步验证 GPT-4 在情感伪标签生成过程中的稳定性优势, 我们将其替换为其他先进的开源大模型 (如 InternLM3 和 Qwen3) 进行对比实验.

由于 MAFW 数据集提供了人工标注的情感描述, 故我们将基于 GPT-4 及其他模型生成的情感伪标签与对应的真实标注进行对比评估, 并在上述四个评估指标下统计其样本维度的标准差, 以量化不同模型在情感描述生成过程中的一致性与稳定性差异. 如表8所示, 各项指标整体呈现出较低的标准差, 表明 GPT-4 在面对不同视频样本时能够保持相对稳定的生成质量, 而非在少数样本上出现显著波动. 进一步地, 通过对 GPT-4 与 InternLM3、Qwen3 在质量与稳定性方面的对比可以观察到, GPT-4 在各项指标上不仅取得了更优的平均性能, 其在样本维度上的波动幅度也相对更小, 体现出更高的生成稳定性.

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

综上所述，实验结果表明 GPT-4 生成的情感伪标签在质量与一致性方面均表现出较为稳定的特性，验证了本文所构建的多粒度情感伪标签在不同视频样本之间具有良好的稳定性，可为后续模型训练提供有效且可靠的监督信号.

表 8 伪标签质量评估与稳定性分析

Table 8 Quality evaluation and stability analysis of pseudo-labels

Method	B-4 ↑	M ↑	R-L ↑	C ↑
InternLM3	1.39±0.11	13.00±0.47	29.56±0.85	**4.71±0.69**
Qwen3	1.55±0.10	13.22±0.53	29.16±0.80	4.69±0.69
GPT-4	**1.89±0.10**	**13.80±0.51**	**30.46±0.73**	4.57±0.67

4.10 情感描述伪标签的影响

为了验证我们提出的多粒度情感伪标签的有效性，我们对比了现有大模型生成的伪标签与我们的多粒度情感伪标签在 CECR-BLIP 上的结果. 实验中，我们使用提示词 “Briefly describe the actions and emotional information of the people in the video” 引导大模型为每个视频生成情感伪标签. 例如，“A man in a suit and glasses looks serious, then speaks with a stern expression”.

实验结果如表9所示，尽管 InternVL2 和 Qwen2.5-VL 能够生成情感相关的描述，但其在 METEOR 和 ROUGE-L 等指标上表现较差. 相比之下，我们的多粒度情感伪标签在多个指标上均取得了最优结果，尤其在 METEOR 和 ROUGE-L 上表现突出. 这表明，我们设计的多粒度情感伪标签不仅能够更充分地捕捉视频中的细粒度情感信息，而且能够从不同层面表达视频所传达的情感，从而显著提升生成描述的质量以及与真实描述的一致性.

表 9 不同情感描述伪标签的影响

Table 9 Influence of different emotional description pseudo-labels

Method	**In-domain setting**				**Out-of-domain setting**			
	B-4 ↑	M ↑	R-L ↑	C ↑	B-4 ↑	M ↑	R-L ↑	C ↑
Generated by InternVL2-2B	1.13	9.73	23.66	6.08	1.17	9.61	23.68	**6.74**
Generated by Qwen2.5-VL-3B	1.68	10.72	24.63	**6.41**	1.80	10.77	24.97	6.42
Multi-granularity emotional pseudo-label	**2.05**	**15.00**	**31.38**	5.78	**2.28**	**15.15**	**32.14**	6.06

4.11 可视化实验与分析

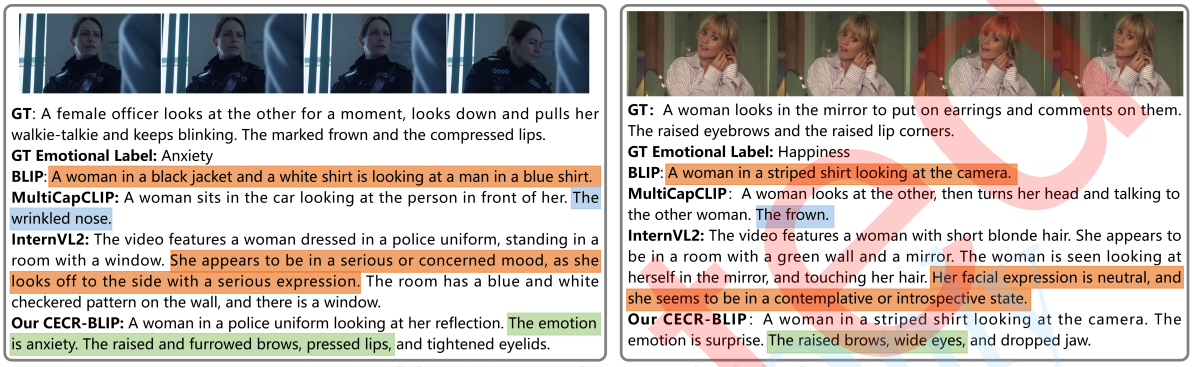
为了直观展示不同方法的情感描述生成效果，我们在域内和域外实验上进行视频-情感描述可视化，将我们的 CECR-BLIP 与 BLIP [14]，MultiCapCLIP [18] 以及多模态大模型 InternVL2 [15] 进行比较，并给出 MAFW 数据集的真实描述，如图11所示. 可视化结果表明，我们的方法能够准确地识别情感，并生成与人脸情感高度相关的描述，而其他方法在这一任务上表现欠佳. 具体分析如下:

由于 BLIP 未在情感标注的数据集上进行训练，因此其生成的描述中缺乏对情感因素的建模与表达. 对于 MultiCapCLIP 方法，其虽然在数据集文本语料库上进行了训练，但其在情感描述任务中的表现仍存在明显不足. 如图11所示，该方法生成的人脸细节描述存在严重的幻觉且部分句子结构不完整. 这表明，只依赖文本数据的方法在情感描述任务中存在固有局限性，且容易产生幻觉. 对于大模型 InternVL2，其生成的描述整体偏长，背景信息占比较高，情感表达则相对不足. 如图11所示，模型通常只能生成 serious 等粗粒度的情感信息，既难以捕捉精细的情感表达，也容易产生情感幻觉.

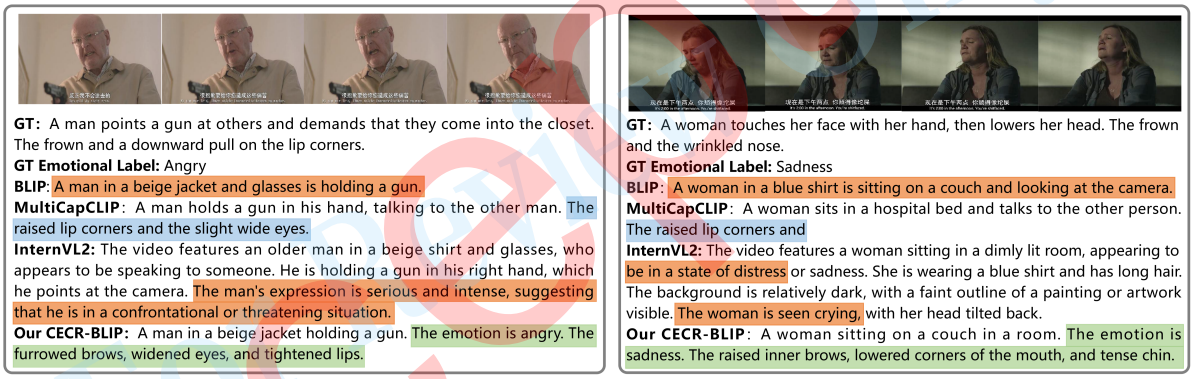
相比之下，我们的 CECR-BLIP 展现出了显著优势. 如图11(a) 中的左图所示，CECR-BLIP 不仅准确识别出了情感类别，还生成了精准的人脸表情描述；图11(b) 中的左图与右图进一步展示了其在情感识别准确率方

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

面的良好性能，并且生成内容与视频内容及情感高度相关．但 CECR-BLIP 仍存在不足，图11(a) 的右图中出现了将 “happiness” 误判为 “surprise” 的情况，这是由于模型只识别了 “扬起的眉毛”，“下垂的下巴” 等特征，而忽略了 “上扬的脸颊” 这一关键细节，因此产生误判，这反映了模型在差异细微的情感类别区分能力上的不足．这一发现为后续方法改进提供了重要方向．



(a) Emotional description visualization under the in-domain setting



(b) Emotional description visualization under the out-of-domain setting

图 11 (网络版彩图) 不同方法生成情感描述可视化．橙色框表示该句子缺乏精细的情感描述且部分存在幻觉，蓝色框表示该句子存在情感幻觉问题，绿色框表示生成的描述精细且准确

Figure 11 (Color online)Visualization of emotional description generated by different methods. The orange box indicates that the sentence lacks fine-grained emotional description and partially contains hallucinated content, the blue box signifies the presence of emotional hallucination in the sentence, the green box represents that the generated description is detailed and accurate

5 结论

本文提出了一种基于反事实因果推理的零样本视频情感描述方法 CECR-BLIP. 该方法通过情感伪标签生成与学习和反事实情感因果推理学习两大模块协同建模，有效增强了生成式视觉语言基础模型 BLIP 的情感语义理解能力，并缓解情感幻觉问题，从而生成精细且准确的情感描述．在实验部分，本文使用 MAFW 和 DFEW 数据集，分别在域内和域外实验设置下验证了 CECR-BLIP 的性能．实验结果表明，CECR-BLIP 在各项评估指标上均优于现有方法，尤其在细粒度情感理解和情感幻觉抑制方面表现突出，充分证明了 CECR-BLIP 的有效性．尽管 CECR-BLIP 在情感语义理解和描述准确性方面取得了良好效果，但在情感描述多样性及情感变化动态建模方面存在一定不足．未来我们计划结合多模态大模型 (如 DeepSeek, Qwen2.5-VL 等)，利用思维链提示技术和因果推理机制协同优化，进一步提升模型对复杂情感场景的理解能力，从而生成更加细腻且多样化的情感描述．

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

参考文献

1 Wang Y, Liu Y Y, Zhou S P, et al. Emotion-oriented cross-modal prompting and alignment for human-centric emotional video captioning. IEEE Transactions on Multimedia, 2025, 27: 3766–3780

2 Lv T, Wen Y H, Sun Z Y, et al. A continuous emotional editing model for talking head videos based on decoupling texture and geometry. Sci Sin Inform, 2023, 53: 2423–2439 [吕天, 温玉辉, 孙志尧, 等. 基于纹理与几何解耦的说话人视频连续情感编辑模型. 中国科学: 信息科学, 2023, 53: 2423–2439]

3 Liu Y Y, Feng S Z, Liu S Y, et al. Sample-cohesive pose-aware contrastive facial representation learning. International Journal of Computer Vision, 2025, 133: 3727–3745

4 Shao Z, Han J G, Debattista K, et al. Textual context-aware dense captioning with diverse words. IEEE Transactions on Multimedia, 2023, 25: 8753–8766

5 Liu Y Y, Wei L, Liu K J, et al. Leveraging eye movement for instructing robust video-based facial expression recognition. IEEE Transactions on Affective Computing, 2025, 16: 1–16

6 Song P P, Guo D, Cheng J, et al. Contextual attention network for emotional video captioning. IEEE Transactions on Multimedia, 2022, 25: 1858–1867

7 Hochreiter S, Schmidhuber J. Long short-term memory. Neural Computation, 1997, 9: 1735–1780

8 Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need. In: Proceedings of the 31st International Conference on Neural Information Processing Systems, Red Hook: Curran Associates, Inc., 2017. 6000–6010

9 Wang H L, Tang P J, Li Q Y, et al. Emotion expression with fact transfer for video description. IEEE Transactions on Multimedia, 2022, 24: 715–727

10 Liu Y Y, Dai W, Feng C X, et al. Mafw: a large-scale, multi-modal, compound affective database for dynamic facial expression recognition in the wild. In: Proceedings of the 30th ACM International Conference on Multimedia, New York: ACM, 2022. 24–32

11 Su Y X, Lan T, Liu Y H, et al. Language models can see: Plugging visual controls in text generation. arXiv, 2022. ArXiv:2205.02655

12 Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision. In: Proceedings of the 38th International Conference on Machine Learning, 2021. 8748–8763

13 Radford A, Wu J, Child R, et al. Language models are unsupervised multitask learners. OpenAI blog, 2019, 1: 1–9

14 Li J N, Li D X, Xiong C M, et al. Blip: bootstrapping language-image pre-training for unified vision-language understanding and generation. In: Proceedings of the International Conference on Machine Learning, Baltimore, 2022. 12888–12900

15 Chen Z, Wang W Y, Cao Y, et al. Expanding performance boundaries of open-source multimodal models with model, data, and test-time scaling. arXiv, 2025. ArXiv:2412.05271

16 Song P P, Guo D, Yang X, et al. Emotion-prior awareness network for emotional video captioning. In: Proceedings of the 31st ACM International Conference on Multimedia, New York: ACM, 2023. 589–600

17 Wang X, Wu J W, Zhang D, et al. Learning to compose topic-aware mixture of experts for zero-shot video captioning. Proceedings of the AAAI Conference on Artificial Intelligence, 2019, 33: 8965–8972

18 Yang B, Liu F L, Wu X, et al. Multicapclip: auto-encoding prompts for zero-shot multilingual visual captioning. In: Proceedings of the Annual Meeting of the Association for Computational Linguistics, Toronto, 2023. 11908 - 11922

19 Zeng D L, Shen Y, Lin M, et al. Zero-shot image captioning with multi-type entity representations. In: Proceedings of the Thirty-Ninth AAAI Conference on Artificial Intelligence. AAAI Press, 2025

20 Tewel Y, Shalev Y, Nadler R, et al. Zero-shot video captioning with evolving pseudo-tokens. arXiv, 2022. ArXiv:2207.11100

21 Nukrai D, Mokady R, Globerson A. Text-only training for image captioning using noise-injected clip. arXiv, 2022. ArXiv:2211.00575

22 Yao L Y, Chu Z X, Li S, et al. A survey on causal inference. ACM Transactions on Knowledge Discovery from Data, 2021, 15: 1–46

23 Lu N Y, Huang S J, Jiang B, et al. Deep causal inference for fault root cause diagnosis. Sci Sin Inform, 2025, 55: 1673–1686 [陆宁云, 黄守金, 姜斌, 等. 基于深度因果推理的故障根因诊断方法. 中国科学: 信息科学, 2025, 55: 1673–1686]

24 Goyal Y, Wu Z Y, Ernst J, et al. Counterfactual visual explanations. In: Proceedings of the 36th International Conference on Machine Learning, Los Angeles, 2019. 2376–2384

25 Yue Z Q, Wang T, Sun Q R, et al. Counterfactual zero-shot and open-set visual recognition. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Piscataway: IEEE, 2021. 15404–15414

26 Yang D K, Li M C, Xiao D L, et al. Towards multimodal sentiment analysis debiasing via bias purification. In: Proceedings of the European Conference on Computer Vision, Berlin, Heidelberg: Springer-Verlag, 2024. 464–481

27 Yang D K, Yang K, Kuang H P, et al. Towards context-aware emotion recognition debiasing from a causal demystification perspective via de-confounded training. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46: 10663–10680

28 Cao Q, Chen X, Song R H, et al. See or guess: counterfactually regularized image captioning. In: Proceedings of the 32nd ACM International Conference on Multimedia, New York: ACM, 2024. 965–974

29 Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: transformers for image recognition at scale. arXiv, 2020. ArXiv:2010.11929

30 Zhang K P, Zhang Z P, Li Z F, et al. Joint face detection and alignment using multitask cascaded convolutional networks. IEEE Signal Processing Letters, 2016, 23: 1499–1503

Accepted by SSI

https://www.sciengine.com/doi/10.1360/SSI-2025-0435

31 Pearl J. Causality: Models, Reasoning and Inference. 2nd edition. Cambridge: Cambridge University Press, 2009. 128-146
32 Pearl J. Direct and indirect effects. In: Proceedings of the Seventeenth Conference on Uncertainty in Artificial Intelligence, San Francisco: Morgan Kaufmann Publishers Inc., 2001. 411–420
33 Jiang X X, Zong Y, Zheng W M, et al. Dfew: a large-scale database for recognizing dynamic facial expressions in the wild. In: Proceedings of the 28th ACM International Conference on Multimedia, New York: ACM, 2020. 2881–2889
34 Papineni K, Roukos S, Ward T, et al. Bleu: a method for automatic evaluation of machine translation. In: Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics, Philadelphia, Pennsylvania, 2002. 311–318
35 Banerjee S, Lavie A. Meteor: an automatic metric for mt evaluation with improved correlation with human judgments. In: Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization, Ann Arbor, 2005. 65–72
36 Lin C Y. Rouge: a package for automatic evaluation of summaries. In: Proceedings of Text Summarization Branches Out, 2004. 74–81
37 Vedantam R, Lawrence Z C, Parikh D. Cider: consensus-based image description evaluation. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Piscataway: IEEE, 2015. 4566–4575
38 Chen X, Fang H, Lin T Y, et al. Microsoft coco captions: data collection and evaluation server. arXiv, 2015. ArXiv:1504.00325
39 Tewel Y, Shalev Y, Schwartz I, et al. Zerocap: zero-shot image-to-text generation for visual-semantic arithmetic. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Piscataway: IEEE, 2022. 17918–17928
40 Zhang B Q, Li K H, Cheng Z S, et al. Videollama 3: frontier multimodal foundation models for image and video understanding. arXiv, 2025. ArXiv:2501.13106
41 Bai S, Chen K Q, Liu X J, et al. Qwen2.5-vl technical report. arXiv, 2025. ArXiv:2502.13923
42 Rohrbach A, Hendricks L A, Burns K, et al. Object hallucination in image captioning. In: Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, Brussels, Belgium: Association for Computational Linguistics, 2018. 4035–4045

Zero-shot video emotional description generation based on counterfactual emotional causal reasoning

Lv KE[1†], Yuxuan HUANG[1†], Yuanyuan LIU[1*], Ying QIAN[1], Chang TANG[2], Zhiqiang ZOU[3] & Hongyan ZHANG[1]

1. *School of Computer Science, China University of Geosciences (Wuhan), Wuhan 430078, China*
2. *School of Software, Huazhong University of Science and Technology, Wuhan 430074, China*
3. *School of Computer Science, Nanjing University of Posts and Telecommunications, Nanjing 210023, China*
* Corresponding author. E-mail: liuyy@cug.edu.cn
† Equal contribution

Abstract Video emotional description aims to generate natural language text enriched with emotional semantics for video sequences, and has broad application prospects in fields such as human-computer interaction and digital humans. However, existing methods largely rely on large-scale manually annotated video-emotional description pairs for training, which is costly. Although recent vision–language foundation models (e.g., BLIP) have demonstrated certain zero-shot reasoning capabilities, they still exhibit limitations in fine-grained emotion understanding and in generating faithful emotional description. To address these challenges, we propose a Counterfactual Emotional Causal Reasoning enhanced BLIP for zero-shot video emotional description without manual annotations. The proposed method consists of two modules: Emotional Pseudo-label Generation and Learning and Counterfactual Emotional Causal Reasoning Learning. The former constructs multi-granularity emotional pseudo-label for each video across three dimensions—global content, global emotion, and facial expression—and introduces an emotional semantic description loss to enhance the fine-grained emotion modeling capability of BLIP. The latter models the causal relationship between vision and language based on the Natural Direct Effect, thereby mitigating emotional hallucination. During inference, the enhanced BLIP is capable of generating accurate and coherent emotional description. Experiments are conducted on two video emotional description datasets, MAFW and DFEW, under both in-domain and out-of-domain settings. Experimental results show that the proposed method consistently outperforms existing approaches on four evaluation metrics, verifying its effectiveness and superiority.

Keywords video emotional description, zero-shot learning, counterfactual causal reasoning, emotional hallucination, generative vision-language model

Accepted by SCIENCE CHINA Information Sciences

https://www.sciengine.com/doi/10.1360/SSI-2025-0435